



Prevendo o Preço de Veículos com Machine Learning

Como transformar dados de carros em previsões inteligentes — explicado de forma simples, do problema ao resultado.

Já se perguntou como uma máquina pode nos ajudar em diversos problemas onde queremos encontrar padrões?

Transformando uma Pergunta de Negócio em um Problema de ML



Pergunta central: "Com base nas características de um veículo, conseguimos estimar seu preço de venda?"

Variável Resposta

O que queremos prever: o **preço do veículo**

Variáveis Preditoras

As características que usamos: ano, km, combustível, modelo...

Análise Exploratória: Conhecer os Dados Antes de Tudo

Antes de ensinar qualquer coisa à máquina, precisamos entender o que os dados estão nos dizendo.



Distribuição de Preços

Identificamos a faixa típica de valores e possíveis preços extremos que poderiam distorcer o modelo.



Correlação entre Variáveis


Verificamos quais características têm relação com o preço. Ex: ano mais novo → preço maior.




Preço por Categoria

Comparamos preços entre tipos: automático vs. manual, gasolina vs. diesel, diferentes modelos.

Alguns gráficos que demonstram o que estamos estudando nessa etapa






É importante verificar a distribuição da nossa variável de interesse para poder realizar transformações nela com o objetivo de facilitar o treinamento do modelo.



No gráfico a direita, vemos como é a distribuição dos pontos entre duas variáveis numéricas também é uma possibilidade de checar correlação entre variáveis.


Para garantir um melhor desempenho do modelo, é importante verificar como é a correlação entre as variáveis para que não haja nenhum tipo de viés na análise do modelo que será implementado.





O principal objetivo de um box-plot é verificar como se comporta a distribuição dos dados quando comparamos diferentes categorias. Qual a diferença entre os gráficos apresentados?

Limpeza e Preparação: Falando a Língua da Máquina



Removendo Dados Inconsistentes

Valores fora de contexto (ex: carro com 500.000 km ou ano 2099) confundem o modelo — como respostas erradas em uma prova.

Transformando Categorias em Números

Computadores só entendem números. Duas estratégias:

One-Hot Encoding

Gasolina → [1,0,0] · Diesel → [0,1,0] · Etanol → [0,0,1]


Label Encoding

Cada categoria vira um número inteiro. Usado para comparar desempenho.

Normalização: Colocando Tudo na Mesma Régua

Por que normalizar?

Algumas variáveis têm escalas muito diferentes. Sem normalização, algoritmos podem dar mais peso a números grandes — mesmo que não sejam mais importantes.



Treino e Teste: Aprendizado com Prova Real

"É como estudar para uma prova com exercícios e depois fazer a avaliação com questões novas."

Base de Treino

~67% dos dados. O modelo **aprende** os padrões de preço.

Base de Teste


~33% dos dados. O modelo é **avaliado** com dados nunca vistos.

Generalização

O objetivo é funcionar bem em **carros novos**, não só nos que já conhece.



Os 4 Algoritmos que Treinamos



Regressão Linear

Traça uma linha que melhor se ajusta aos dados. Simples e interpretável, mas limitado a relações lineares.



Árvore de Decisão

Como um especialista fazendo perguntas: "É automático? Tem menos de 50 mil km?" — até chegar ao preço.



XGBoost

Combina várias árvores sequencialmente, cada uma corrigindo os erros da anterior. Muito preciso.



LightGBM

Similar ao XGBoost, mas mais rápido e eficiente com grandes volumes de dados.

Como Sabemos Qual Modelo é Melhor?

Métricas de Avaliação

RMSE



Erro médio — penaliza erros grandes. Ex: RMSE = R\$3.000 significa que, em média, o modelo erra esse valor.

MAE e MAPE



Erro absoluto médio — mais intuitivo. Mostra o desvio médio sem penalizar tanto outliers.
Erro absolute médio percentual — intuitivo assim como o MAE, tem a mesma ideia mas aplicada a percentual.

R^2 e R^2 Ajustado



Quanto do preço o modelo explica. $R^2 = 0,85$ significa que 85% da variação é capturada.

Após uma longa análise e treinamento, escolhemos o modelo: LightGBM

- RMSE: 1231,02
- MAE: 823,55
- MAPE: 6,94%
- R^2 : 0,93295
- R^2 Ajustado:

Otimização: Ajustando a Receita Perfeita



O que são Hiperparâmetros?

São as "configurações" do algoritmo — definidas **antes** do treino. Ex: quantas árvores usar, qual a profundidade máxima.

Como o GridSearchCV Funciona

Testa sistematicamente combinações de configurações e escolhe a que produz o melhor resultado.

Do Dado Bruto à Previsão Inteligente



Dados

Coleta das características dos veículos



Entendimento

Análise exploratória e correlações



Preparação

Limpeza, codificação e normalização



Treinamento

Modelos aprendem padrões



Modelo Final

Previsão de preço com precisão

Este projeto mostra como **Machine Learning transforma dados em decisão de negócio** — estimando preços de forma rápida, consistente e baseada em evidências.